calidad-del-aire-duitama

August 13, 2025

1 CALIDAD DEL AIRE CIUDAD DE DUITAMA

1.1 DATASET

La vertical de calidad de aire de Duitama está compuesta por sensores IoT que realizan las mediciones de diferentes contaminantes ubicados en diferentes puntos de la ciudad, como se enuncia a continuación:

1. Sensor de calidad del aire desarrollado por el Centro Internacional de Física de la Universidad Nacional de Colombia CIF

• Nombres de los dispositivos en el set de datos: AirQualityUnit01, AirQualityUnit02, AQ_SEP • Variables de medición: Temperatura, Humedad relativa, CO2, CO, PM2.5, PM5, PM10 • Tasa de transmisión: cada 5 min • Lugares de instalación: - Antiguo Terminal de transportes de Duitama, Calle 17 # 18-32 - Avenida circunvalar # 16A - 18, Duitama, Boyacá - Calle 20 # 30-00, Avenida Camillo Torres con carrera 30, Duitama, Boyacá

1.2 ¿Cual es el problema?

- Este proyecto tiene como objetivo desarrollar un modelo que permita estimar los principales contaminantes atmosféricos utilizados para evaluar la calidad del aire, con el fin de optimizar la vigilancia ambiental, reducir costos en sensores físicos y mejorar la identificación de contaminantes críticos.
- Uno de los mayores desafíos es la medición del PM . , un material particulado ultrafino que, por su pequeño tamaño, puede comportarse como gas, verse afectado por condiciones como la humedad relativa y requerir equipos costosos para su medición. Además, es altamente peligroso para la salud, ya que puede ingresar al sistema respiratorio y alcanzar el torrente sanguíneo, aumentando el riesgo de enfermedades graves.
- El modelo propuesto busca estimar este tipo de contaminantes a partir de variables ambientales más accesibles, como temperatura, humedad o concentraciones de otros compuestos, permitiendo una gestión más eficiente y económica de la calidad del aire.

[ ]:
```
# Importacion de librerias
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import matplotlib.dates as mdates
from sklearn.model_selection import train_test_split
```

```
import tensorflow as tf
from tensorflow.keras import layers, models
from sklearn.preprocessing import StandardScaler
```

2 1. Importacion de Data

[ ]:
```
url = "https://www.datos.gov.co/resource/aghd-ge2f.json"
aire = pd.read_json(url)
```

[ ]:
```
aire.info() # No se presentan datos faltantes
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 9 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   fecha             1000 non-null   object
 1   nombre_equipo     1000 non-null   object
 2   co                1000 non-null   int64
 3   co2               1000 non-null   int64
 4   pm10              1000 non-null   int64
 5   pm2_5             1000 non-null   int64
 6   pm5               1000 non-null   int64
 7   humedad_relativa  1000 non-null   float64
 8   temperatura       1000 non-null   float64
dtypes: float64(2), int64(5), object(2)
memory usage: 70.4+ KB
```

2.0.1 Conclusiones

- No se presentan valores nulos
- La variable fecha no esta propiamente como tipo DateTime. Se debe hacer la conversión de tipo de dato.

[ ]:
```
aire.head(5) # Los datos estan de acuerdo a la descripción
```

[ ]:

	fecha	nombre_equipo	co	co2	pm10	pm2_5	pm5	humedad_relativa	temperatura
0	2023-08-01T00:00:19.000	AirQualityUnit02	2	450	5	4	4	0.0	0.0
1	2023-08-01T00:02:25.000	AirQualityUnit02	3	448	6	6	4	65.4	13.6
2	2023-08-01T00:04:31.000	AirQualityUnit02	4	453	26	22	14	52.7	0.8
3	2023-08-01T00:08:36.000	AirQualityUnit02	6	459	13	10	7		
4	2023-08-01T00:10:41.000	AirQualityUnit02	7	461	10	9	6		

```
3              0.0          0.0
4             53.0          0.8
```

[ ]:
```
aire["fecha"] = pd.to_datetime(aire['fecha']) # Se convierte la columna fecha␣
 ↪(object) - datetime pandas
```

[ ]:
```
# RANGO DE CAPTURA DE DATOS
rango = aire['fecha'].max() - aire['fecha'].min()
print("Duración total:", rango)
print('Fecha inicial: ', aire['fecha'].min(), ' - ', 'Fecha final: ',␣
 ↪aire['fecha'].max())
```

```
Duración total: 3 days 11:44:43
Fecha inicial:  2023-08-01 00:00:19  -  Fecha final:  2023-08-04 11:45:02
```

2.1 Conclusiones

- Las mediciones corresponden a aproximadamente 3 dias y medio correspondientes a las fechas de 01 de agosto de 2023 hasta el 4 de agosto de 2023. Estos dias correspondian al dia martes hasta el dia viernes.

2.2 Visualización del comportamiento de los datos de entrada

[ ]:
```
# Diccionario con los límites máximos permisibles en 24h (según la normativa␣
 ↪colombiana)
limites_24h = {
    'pm10': 75,       # µg/m³
    'pm2_5': 37,      # µg/m³
    'pm5': 37,        # usaremos el mismo que para PM2.5
    'co': 30.55,       # 35.000 microgramos/m3 equivale a 30.55 ppm para CO␣
 ↪segun formula de gases ideales
    'co2': None
}

fig, axs = plt.subplots(4, 2, figsize=(14, 12))
axs = axs.flatten()

formato_hora = mdates.DateFormatter('%H:%M:%S')

variables = [
    ('co', 'Monóxido de carbono (ppm)'),
    ('co2', 'Dióxido de carbono (ppm)'),
    ('pm10', 'PM10 (µg/m³)'),
    ('pm2_5', 'PM2.5 (µg/m³)'),
    ('pm5', 'PM5 (µg/m³)'),
    ('humedad_relativa', 'Humedad relativa (%)'),
    ('temperatura', 'Temperatura (°C)')
```

```
]

for i, (columna, titulo) in enumerate(variables):
    axs[i].plot(aire['fecha'], aire[columna], label=titulo)
    axs[i].set_title(titulo)
    axs[i].xaxis.set_major_formatter(formato_hora)
    axs[i].set_xlabel('Hora')
    axs[i].grid(True)
    axs[i].tick_params(axis='x', rotation=45)

    # Agregar línea punteada roja si hay límite para la variable
    if columna in limites_24h and limites_24h[columna] is not None:
        axs[i].axhline(y=limites_24h[columna], color='red', linestyle='--',␣
 ↪linewidth=1.5, label='Límite 24h')
        axs[i].legend()

# Ocultar subplots vacíos si sobran
if len(variables) < len(axs):
    for j in range(len(variables), len(axs)):
        axs[j].axis('off')

plt.tight_layout()
plt.show()
```

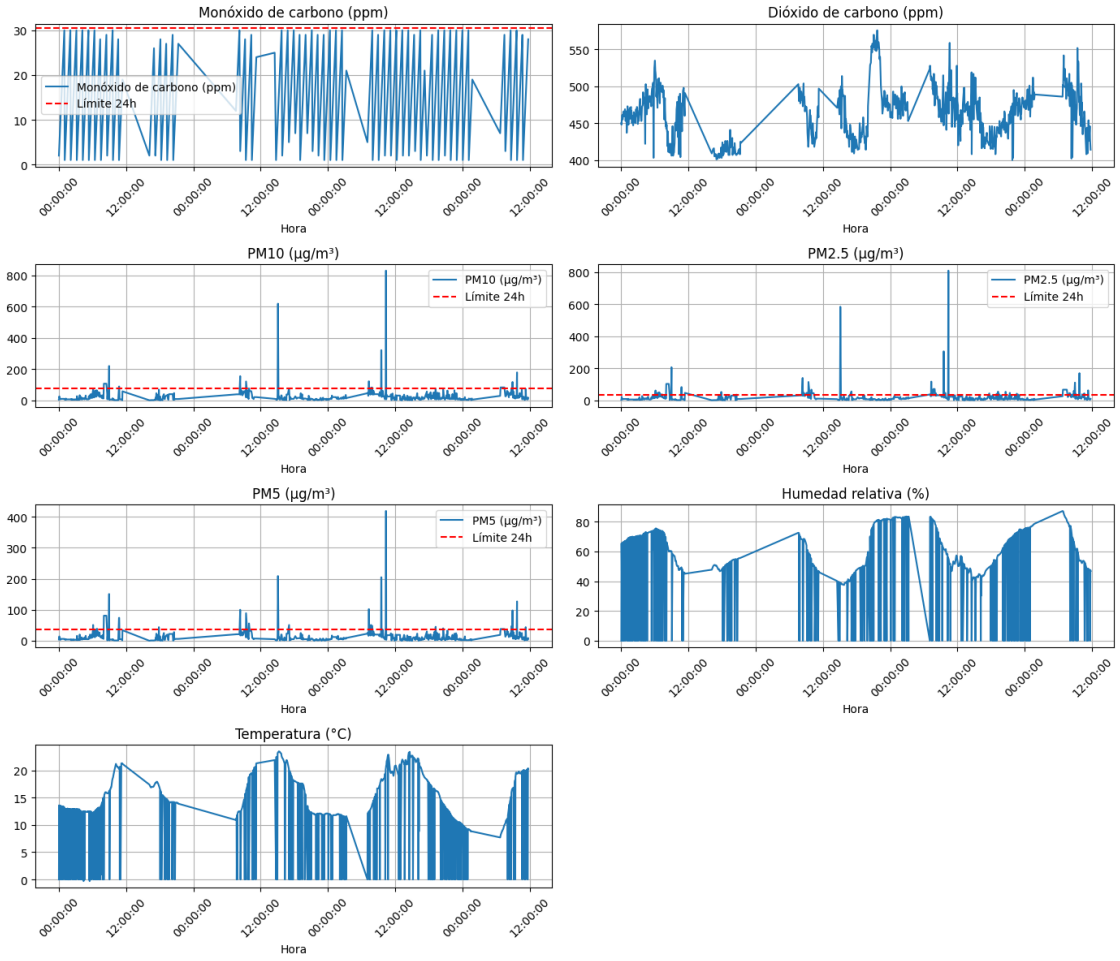

2.2.1 Conclusiones

- Se observan algunos valores atipicos para los valores de humedad relativa y temperatura ya que estos valores no pueden caer abruptamente a cero y recuperarse, se buscará imputar los valores.

2.3 Diagrama de Cajas para las variables

[ ]:
```
# DIAGRAMA DE CAJAS
variables = [
    ('co', 'Monóxido de carbono (ppm)'),
    ('co2', 'Dióxido de carbono (ppm)'),
    ('pm10', 'PM10 (µg/m³)'),
    ('pm2_5', 'PM2.5 (µg/m³)'),
    ('pm5', 'PM5 (µg/m³)'),
    ('humedad_relativa', 'Humedad relativa (%)'),
    ('temperatura', 'Temperatura (°C)')
```

```
]

# Configuración
sns.set(style="whitegrid")
num_variables = len(variables)
columnas = 2
filas = (num_variables + columnas - 1) // columnas

# Crear subgráficos
fig, axes = plt.subplots(filas, columnas, figsize=(10, 2 * filas))
axes = axes.flatten()

# Crear los boxplots horizontales
for i, (columna, titulo) in enumerate(variables):
    sns.boxplot(data=aire, x=columna, ax=axes[i], color='skyblue', orient='h')
    axes[i].set_title(titulo)
    axes[i].set_xlabel('')
    axes[i].set_ylabel('')

# Eliminar ejes vacíos si los hay
for j in range(i + 1, len(axes)):
    fig.delaxes(axes[j])

plt.tight_layout()
plt.show()
```

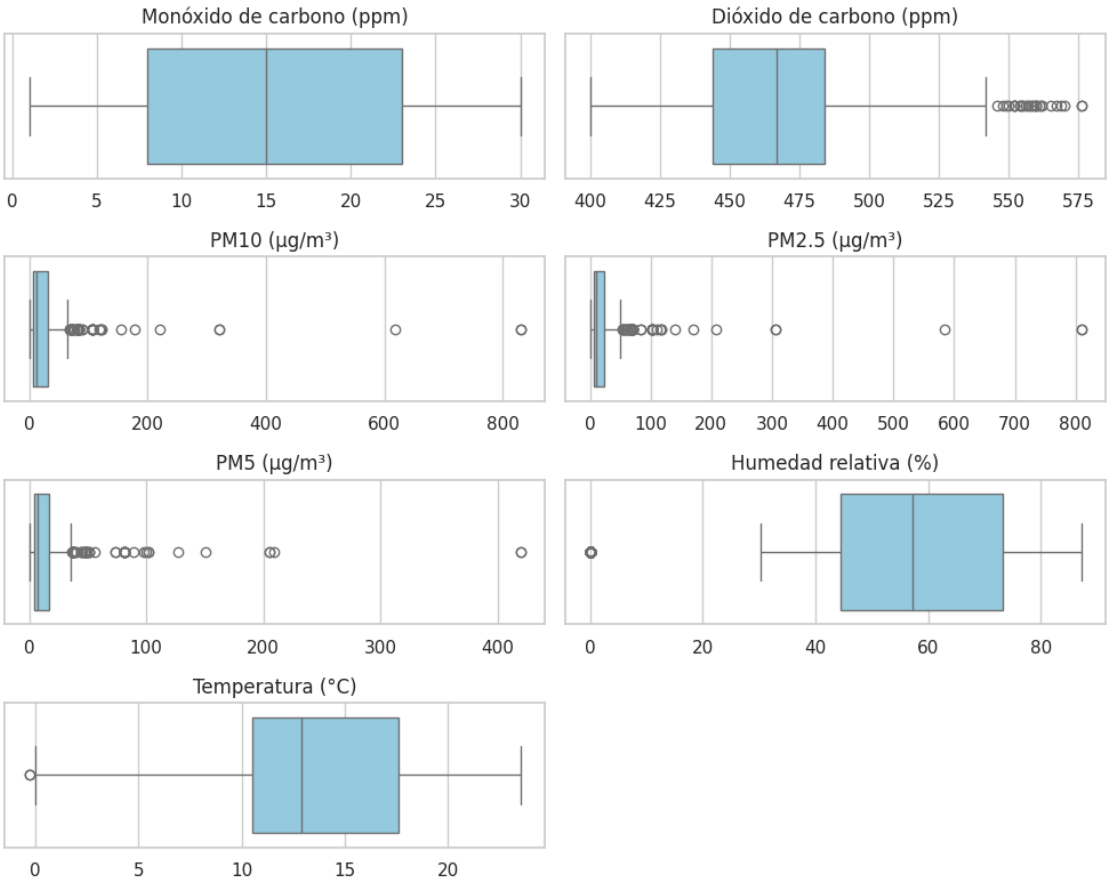

2.4 Imputacion de Datos para variables Humedad relativa y temperatura

2.4.1 Distribucion de datos Humedad y temperatura

[ ]:
```
# Estilo visual
sns.set(style="whitegrid")

# Crear subplots: una fila, dos columnas
fig, axes = plt.subplots(1, 2, figsize=(12, 4))

# Distribución de la humedad relativa
sns.histplot(aire['humedad_relativa'], kde=True, color='skyblue', ax=axes[0])
axes[0].set_title('Distribución de Humedad Relativa (%)')
axes[0].set_xlabel('Humedad relativa (%)')

# Distribución de la temperatura
sns.histplot(aire['temperatura'], kde=True, color='salmon', ax=axes[1])
axes[1].set_title('Distribución de Temperatura (°C)')
axes[1].set_xlabel('Temperatura (°C)')
```

```
plt.tight_layout()
plt.show()
```

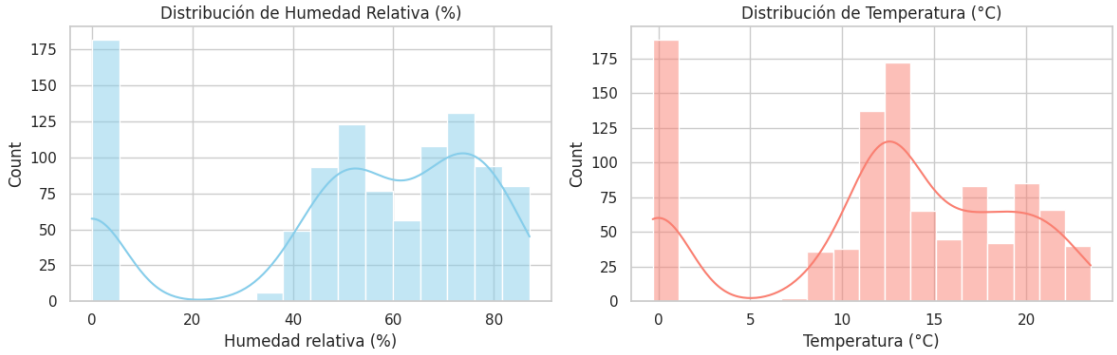

2.4.2 Correccion variable Humedad relativa

[ ]:
```
humedad = aire['humedad_relativa'].copy()
humedad_corregida = humedad.copy()

i = 0
while i < len(humedad):
    if humedad[i] == 0:
        # Inicia un bloque de ceros
        inicio = i
        while i < len(humedad) and humedad[i] == 0:
            i += 1
        fin = i  # posición del primer valor no cero después del bloque

        # Obtener valor anterior no cero
        if inicio > 0:
            valor_anterior = humedad[inicio - 1]
        else:
            valor_anterior = np.nan  # inicio del vector

        # Obtener valor posterior no cero
        if fin < len(humedad):
            valor_posterior = humedad[fin]
        else:
            valor_posterior = np.nan  # final del vector

        # Imputar con el promedio si ambos valores existen
        if not np.isnan(valor_anterior) and not np.isnan(valor_posterior):
            promedio = (valor_anterior + valor_posterior) / 2
            humedad_corregida[inicio:fin] = promedio
```

```
        # Si solo uno de los dos existe, usar ese
        elif not np.isnan(valor_anterior):
            humedad_corregida[inicio:fin] = valor_anterior
        elif not np.isnan(valor_posterior):
            humedad_corregida[inicio:fin] = valor_posterior
        # Si ambos son NaN, deja como está

    else:
        i += 1

# Reemplazamos la columna original con la corregida
aire['humedad_relativa'] = humedad_corregida

# Graficar antes y después
plt.figure(figsize=(14, 4))
plt.plot(aire['fecha'], humedad, label='Original (con ceros)', linestyle='--',␣
 ↪alpha=0.5)
plt.plot(aire['fecha'], humedad_corregida, label='Corregida', linewidth=2)
plt.xlabel('Fecha')
plt.ylabel('Humedad relativa (%)')
plt.title('Corrección de valores de humedad = 0')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

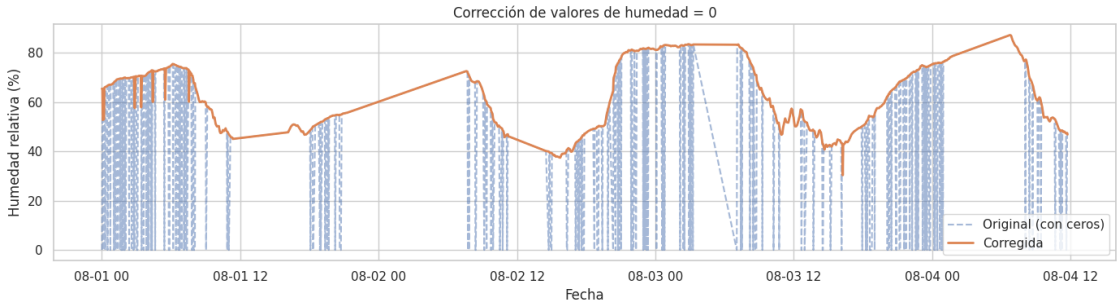

2.4.3 Correccion variable temperatura

[ ]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

# Copiar la serie original
temperatura = aire['temperatura'].copy()
temperatura_corregida = temperatura.copy()
```

```
# Contador de valores corregidos
corregidos = 0

i = 0
while i < len(temperatura):
    if temperatura[i] == 0:
        # Inicia bloque de ceros
        inicio = i
        while i < len(temperatura) and temperatura[i] == 0:
            i += 1
        fin = i

        # Buscar valor anterior y posterior no cero
        valor_anterior = temperatura[inicio - 1] if inicio > 0 else np.nan
        valor_posterior = temperatura[fin] if fin < len(temperatura) else np.nan

        # Calcular valor de imputación
        if not np.isnan(valor_anterior) and not np.isnan(valor_posterior):
            promedio = (valor_anterior + valor_posterior) / 2
        elif not np.isnan(valor_anterior):
            promedio = valor_anterior
        elif not np.isnan(valor_posterior):
            promedio = valor_posterior
        else:
            promedio = 0  # No hay con qué imputar

        # Reemplazar en el bloque
        temperatura_corregida[inicio:fin] = promedio
        corregidos += (fin - inicio)

    else:
        i += 1

# Reemplazar columna original
aire['temperatura'] = temperatura_corregida

# Mostrar cantidad corregida
print(f"  Se corrigieron {corregidos} valores de temperatura igual a cero.")

# Graficar comparación
plt.figure(figsize=(14, 4))
plt.plot(aire['fecha'], temperatura, label='Original (con ceros)',␣
 ↪linestyle='--', alpha=0.5)
plt.plot(aire['fecha'], temperatura_corregida, label='Corregida', linewidth=2)
plt.xlabel('Fecha')
plt.ylabel('Temperatura (°C)')
```

```
plt.title('Corrección de valores de temperatura = 0')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

```
Se corrigieron 182 valores de temperatura igual a cero.
```

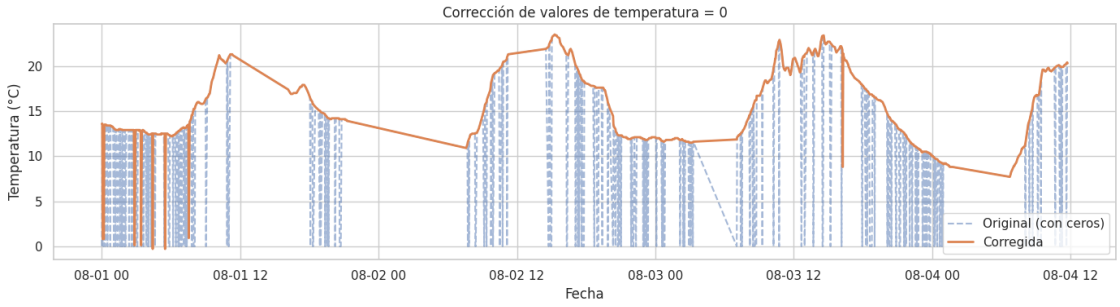

2.4.4 Conclusiones

- Aunque el comportamiento de los datos mejoro significativamente hay algunos datos que aun no concuerdan con el comportamiento de las dos variables. Sin embargo, para no volver tan sinteticos los datos, se procedera con el proyecto con esta unica imputaión.

2.5 Matriz de dispersion para las variables numéricas

[ ]:
```
aire_dispersion = aire.drop(columns=['fecha'])
sns.pairplot(aire_dispersion, height=1.5)  # Matriz de dispersion de todas las␣
↪variables
plt.show()
```

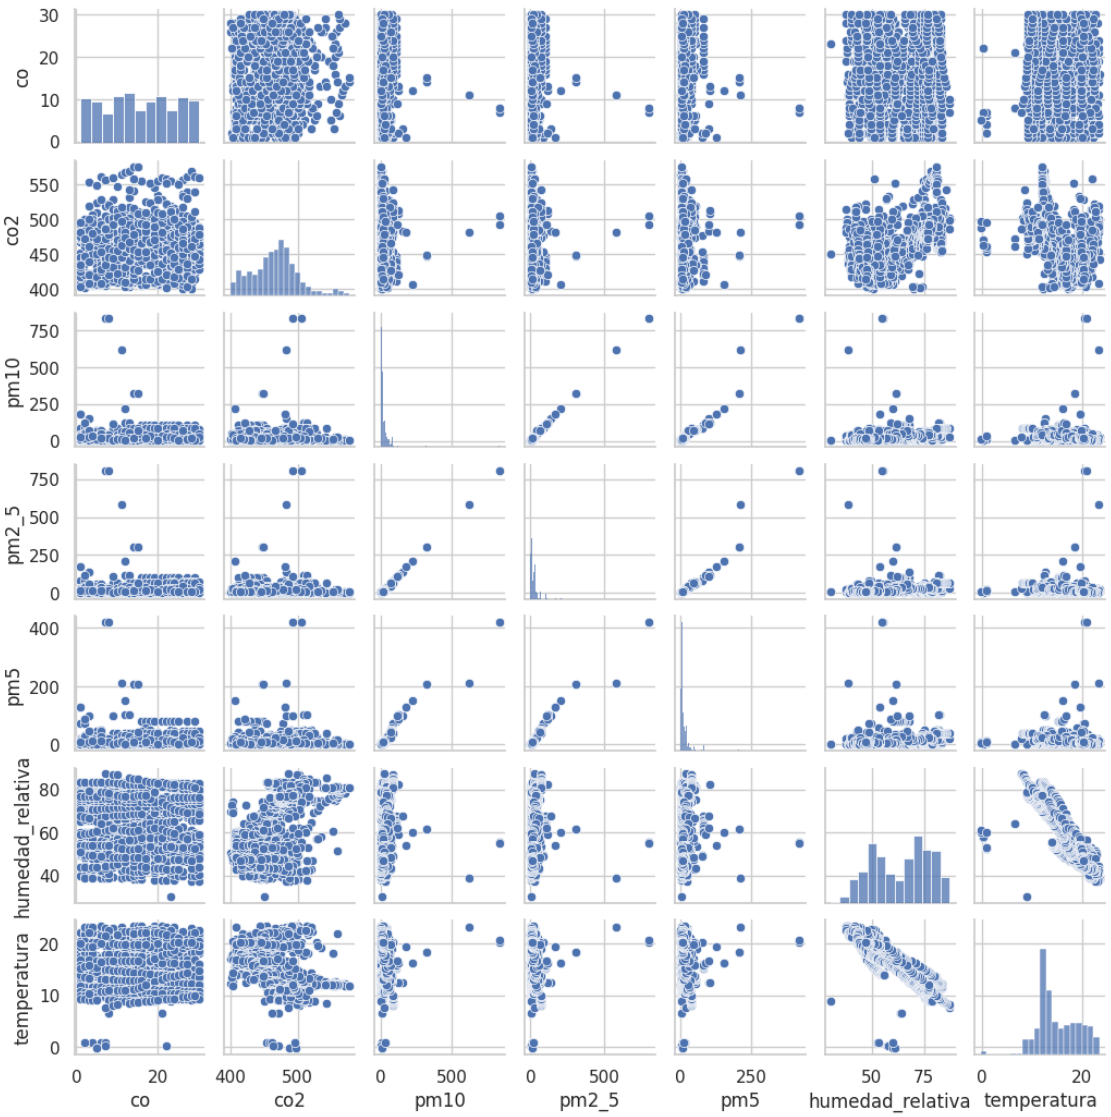

2.5.1 Conclusiones

- Se debe verificar si las condiciones de humedad y temperatura para f(x)=0 son correctas ya que pueden ser fallas de los sensores.

[ ]:
```
# Cambiando el formato de la fecha para el modelo
aire['hora_decimal'] = (
    aire['fecha'].dt.hour +
    aire['fecha'].dt.minute / 60 +
    aire['fecha'].dt.second / 3600
)
aire.head(3)
```

[ ]:

	fecha	nombre_equipo	co	co2	pm10	pm2_5	pm5	\
0	2023-08-01 00:00:19	AirQualityUnit02	2	450	5	4	4	
1	2023-08-01 00:02:25	AirQualityUnit02	3	448	6	6	4	
2	2023-08-01 00:04:31	AirQualityUnit02	4	453	26	22	14	

	humedad_relativa	temperatura	hora_decimal
0	65.4	13.6	0.005278
1	65.4	13.6	0.040278
2	52.7	0.8	0.075278

3 2. Modelo Regresion para estimar el CO en funcion de los demas parametros

- Se analiza inicialmente la correlacion lineal de las variables para dar una aproximación de la efectividad del modelo y que variables tienden a ser las mas relevantes.

[ ]:
```
# Matriz de correlación
data_matriz = aire.drop(columns=['fecha', 'nombre_equipo'])
matriz_corr = data_matriz.corr(method='pearson') #method='spearman')

plt.figure(figsize=(10, 8))
sns.heatmap(matriz_corr, annot=True, fmt=".2f", cmap="coolwarm", square=True)
plt.title("Matriz de correlación (incluyendo CO)")
plt.tight_layout()
plt.show()
```

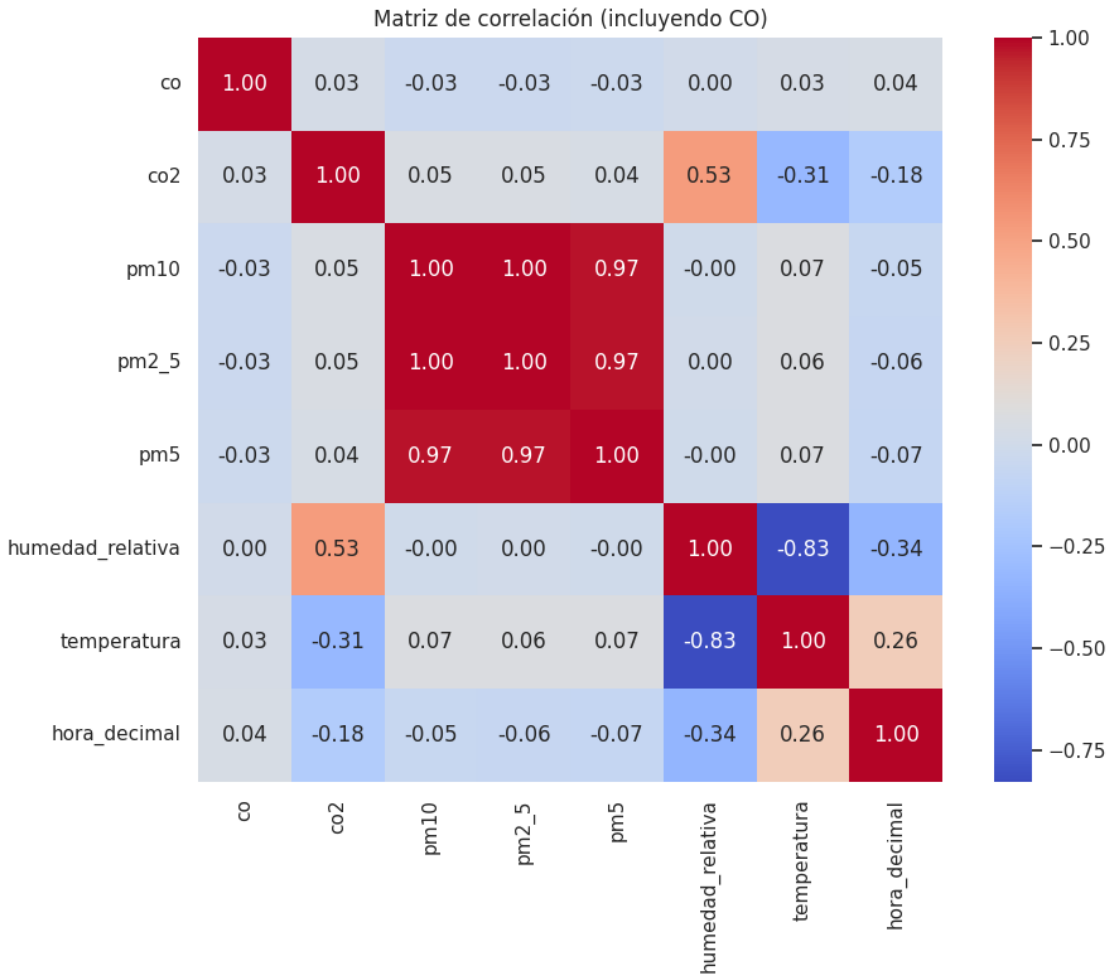

[ ]:
```
# 1. Seleccionando los datos
X = aire.drop(columns=['co','fecha', 'nombre_equipo'])  # Eliminando columnas
y = aire['co']
```

[ ]:
```
# 2. División 70% entrenamiento / 30% prueba
X_entrenamiento, X_prueba, y_entrenamiento, y_prueba = train_test_split(
    X, y, test_size=0.30, random_state=42)
```

[ ]:
```
# 3. Escalamiento # StandarScaler Transforma los datos para que cada columna␣
↪tenga media 0 y desviación estándar 1
escalador = StandardScaler()
X_entrenamiento = escalador.fit_transform(X_entrenamiento)
X_prueba = escalador.transform(X_prueba)
```

[ ]:
```
# Entrenamiento del Modelo
modelo = models.Sequential()
```

```
modelo.add(layers.Dense(64, activation='relu', input_shape=(X_entrenamiento.
 ↪shape[1],)))
modelo.add(layers.Dense(64, activation='relu'))
modelo.add(layers.Dense(64, activation='relu'))
modelo.add(layers.Dense(64, activation='relu'))
modelo.add(layers.Dense(1))  # Salida: valor de CO

modelo.compile(optimizer='adam', loss='mse', metrics=['mae'])

# Entrenamiento
historial = modelo.fit(X_entrenamiento, y_entrenamiento, epochs=100,␣
 ↪validation_data=(X_prueba, y_prueba), verbose=0)

# Mostrar errores del modelo
mae_entrenamiento = historial.history['mae']
mae_validacion = historial.history['val_mae']
loss_entrenamiento = historial.history['loss']  # MSE si usaste loss='mse'
loss_validacion = historial.history['val_loss']

print("MAE final entrenamiento:", mae_entrenamiento[-1])
print("MAE final validación:", mae_validacion[-1])
print("MSE final entrenamiento:", loss_entrenamiento[-1])
print("MSE final validación:", loss_validacion[-1])
```

```
/usr/local/lib/python3.11/dist-packages/keras/src/layers/core/dense.py:87:
UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When
using Sequential models, prefer using an `Input(shape)` object as the first
layer in the model instead.
  super().__init__(activity_regularizer=activity_regularizer, **kwargs)
MAE final entrenamiento: 6.053477764129639
MAE final validación: 7.1864166259765625
MSE final entrenamiento: 53.814117431640625
MSE final validación: 74.24518585205078
```

[ ]:
```
predicciones = modelo.predict(X_prueba)

import matplotlib.pyplot as plt

plt.scatter(y_prueba, predicciones)
plt.xlabel("Valor real de CO")
plt.ylabel("Predicción de CO")
plt.title("Red Neuronal: Predicción vs Real")
plt.grid(True)
plt.show()
```

```
10/10             0s 12ms/step
```

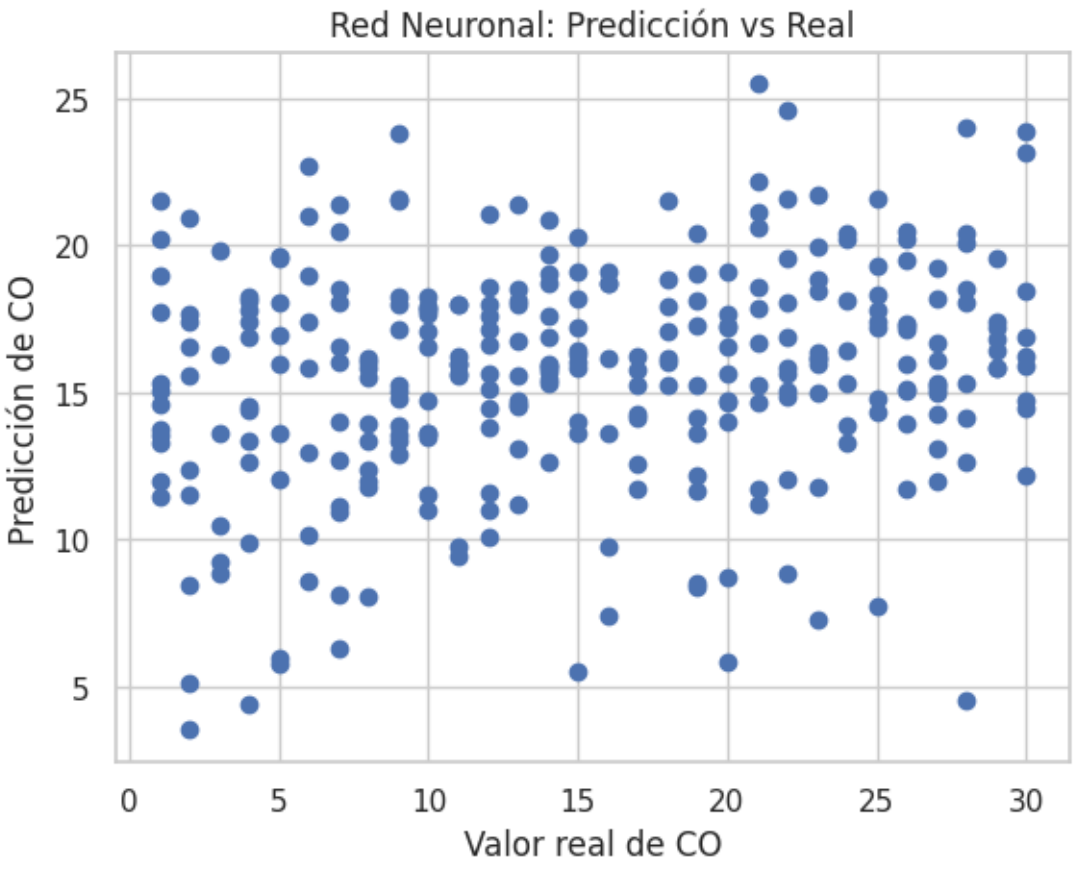

3.1 Analizando otros optimizadores

[ ]:
```
from tensorflow.keras.optimizers import SGD, RMSprop, Adagrad, Adadelta, Adam,␣
 ↪Adamax, Nadam, Ftrl
# Diccionario de optimizadores
optimizadores = {
    'SGD': SGD(learning_rate=0.01),
    'RMSProp': RMSprop(learning_rate=0.001),
    'Adagrad': Adagrad(learning_rate=0.01),
    'Adadelta': Adadelta(learning_rate=1.0),
    'Adam': Adam(learning_rate=0.001),
    'Adamax': Adamax(learning_rate=0.002),
    'Nadam': Nadam(learning_rate=0.002),
    'Ftrl': Ftrl(learning_rate=0.01)
}

# Preparar figura con 2 columnas y N filas
num_opt = len(optimizadores)
fig, axs = plt.subplots(nrows=num_opt, ncols=2, figsize=(14, 4 * num_opt))
```

```
fig.subplots_adjust(hspace=0.4)
fig.suptitle('Comparación de optimizadores: MAE y MSE', fontsize=16, y=1.01)

# Entrenar y graficar por cada optimizador
for i, (nombre, opt) in enumerate(optimizadores.items()):
    print(f"\n Entrenando con: {nombre}")

    # Red neuronal
    modelo = models.Sequential([
        layers.Dense(64, activation='relu', input_shape=(X_entrenamiento.
 ↪shape[1],)),
        layers.Dense(64, activation='relu'),
        layers.Dense(64, activation='relu'),
        layers.Dense(64, activation='relu'),
        layers.Dense(1)
    ])

    modelo.compile(optimizer=opt, loss='mse', metrics=['mae'])

    historial = modelo.fit(
        X_entrenamiento, y_entrenamiento,
        epochs=100,
        validation_data=(X_prueba, y_prueba),
        verbose=0
    )

    # Extraer métricas
    mae_entrenamiento = historial.history['mae']
    mae_validacion = historial.history['val_mae']
    mse_entrenamiento = historial.history['loss']
    mse_validacion = historial.history['val_loss']

    # Mostrar errores finales
    print("MAE final entrenamiento:", mae_entrenamiento[-1])
    print("MAE final validación:", mae_validacion[-1])
    print("MSE final entrenamiento:", mse_entrenamiento[-1])
    print("MSE final validación:", mse_validacion[-1])

    #  Gráfica MAE
    axs[i, 0].plot(mae_entrenamiento, label='Entrenamiento', color='blue')
    axs[i, 0].plot(mae_validacion, label='Validación', color='orange')
    axs[i, 0].set_title(f"{nombre} - MAE")
    axs[i, 0].set_ylabel('MAE')
    axs[i, 0].set_xlabel('Épocas')
    axs[i, 0].legend()
    axs[i, 0].grid(True)
```

```
    #  Gráfica MSE
    axs[i, 1].plot(mse_entrenamiento, label='Entrenamiento', color='green')
    axs[i, 1].plot(mse_validacion, label='Validación', color='red')
    axs[i, 1].set_title(f"{nombre} - MSE")
    axs[i, 1].set_ylabel('MSE')
    axs[i, 1].set_xlabel('Épocas')
    axs[i, 1].legend()
    axs[i, 1].grid(True)

plt.tight_layout()
plt.show()
```

```
 Entrenando con: SGD
MAE final entrenamiento: 5.944210529327393
MAE final validación: 7.31919527053833
MSE final entrenamiento: 53.60799026489258
MSE final validación: 79.34992980957031

 Entrenando con: RMSProp
MAE final entrenamiento: 6.41217565536499
MAE final validación: 7.044591426849365
MSE final entrenamiento: 59.124046325683594
MSE final validación: 71.80392456054688

 Entrenando con: Adagrad
MAE final entrenamiento: 6.8179450035095215
MAE final validación: 7.258756637573242
MSE final entrenamiento: 63.92605972290039
MSE final validación: 71.89147186279297

 Entrenando con: Adadelta
MAE final entrenamiento: 6.5079498291015625
MAE final validación: 7.303773403167725
MSE final entrenamiento: 60.68766784667969
MSE final validación: 75.57556915283203

 Entrenando con: Adam
MAE final entrenamiento: 6.320187091827393
MAE final validación: 7.299553871154785
MSE final entrenamiento: 57.513553619384766
MSE final validación: 76.61739349365234

 Entrenando con: Adamax
MAE final entrenamiento: 6.780349254608154
MAE final validación: 7.244959354400635
MSE final entrenamiento: 63.50979232788086
```

```
MSE final validación: 72.32717895507812

  Entrenando con: Nadam
MAE final entrenamiento: 5.590921878814697
MAE final validación: 7.357107162475586
MSE final entrenamiento: 47.17963790893555
MSE final validación: 78.80044555664062

  Entrenando con: Ftrl
MAE final entrenamiento: 7.30209493637085
MAE final validación: 7.541112422943115
MSE final entrenamiento: 72.22681427001953
MSE final validación: 75.9859390258789
```

Comparación de optimizadores: MAE y MSE

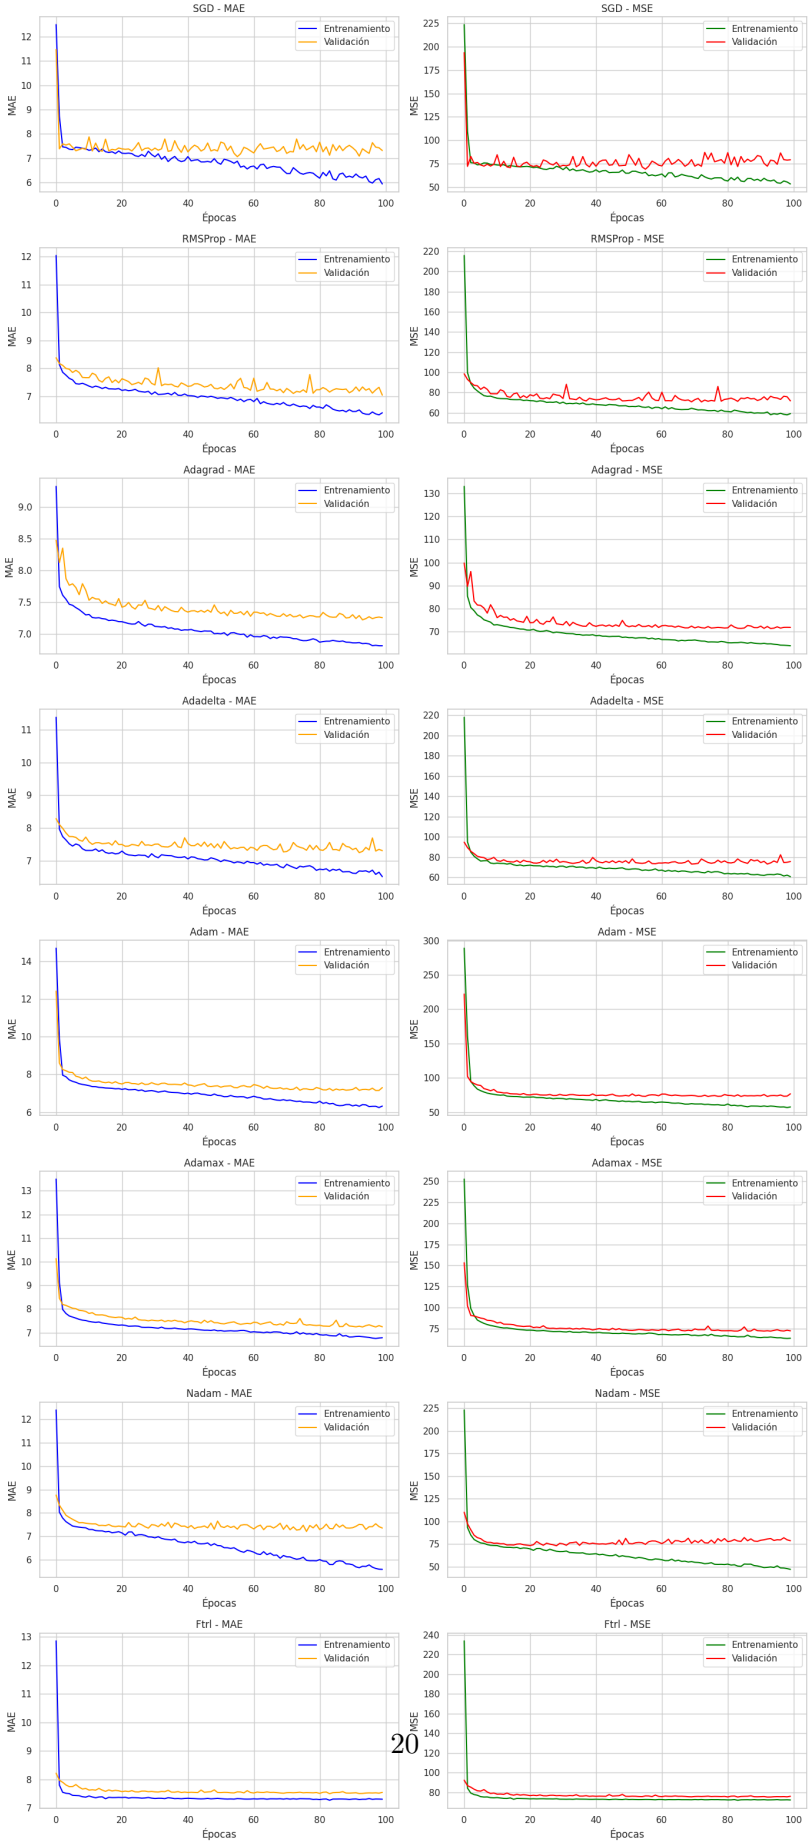

3.2 Conclusiones

- La prediccion de CO en funcion de las demas variables no es optima ya que no hay una correlacion clara entre las variables de entrada y las de salida.
- Se optará por predecir el pm 2.5 ya que tiene mayor correlación.

4 Modelo de Regresion para estimar Material Particulado 2.5 (pm2.5) en funcion de los demas parámetros

[ ]:
```
# 1. Seleccionando los datos
X_pm = aire.drop(columns=['pm2_5','fecha', 'nombre_equipo'])  # Eliminando␣
 ↪columnas
y_pm = aire['pm2_5']
```

[ ]:
```
# 2. División 70% entrenamiento / 30% prueba
X_entrenamiento, X_prueba, y_entrenamiento, y_prueba = train_test_split(
    X_pm, y_pm, test_size=0.30, random_state=42)
```

[ ]:
```
# 3. Escalamiento # StandarScaler Transforma los datos para que cada columna␣
 ↪tenga media 0 y desviación estándar 1
escalador = StandardScaler()
X_entrenamiento = escalador.fit_transform(X_entrenamiento)
X_prueba = escalador.transform(X_prueba)
```

[ ]:
```
# Entrenamiento del Modelo
modelo = models.Sequential()
modelo.add(layers.Dense(64, activation='relu', input_shape=(X_entrenamiento.
 ↪shape[1],)))
modelo.add(layers.Dense(64, activation='relu'))
modelo.add(layers.Dense(1))  # Salida: valor de CO

modelo.compile(optimizer='adam', loss='mse', metrics=['mae'])

# Entrenamiento
historial = modelo.fit(X_entrenamiento, y_entrenamiento, epochs=100,␣
 ↪validation_data=(X_prueba, y_prueba), verbose=1)
```

```
Epoch 1/100
```

```
/usr/local/lib/python3.11/dist-packages/keras/src/layers/core/dense.py:87:
UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When
using Sequential models, prefer using an `Input(shape)` object as the first
layer in the model instead.
  super().__init__(activity_regularizer=activity_regularizer, **kwargs)
```

```
22/22            2s 18ms/step -
loss: 2904.2676 - mae: 20.4911 - val_loss: 580.8759 - val_mae: 15.6219
Epoch 2/100
22/22            0s 8ms/step - loss:
3058.7522 - mae: 20.3455 - val_loss: 520.5283 - val_mae: 14.0113
Epoch 3/100
22/22            0s 7ms/step - loss:
1938.1497 - mae: 16.6337 - val_loss: 437.9926 - val_mae: 12.3330
Epoch 4/100
22/22            0s 8ms/step - loss:
1452.2445 - mae: 14.1481 - val_loss: 356.8097 - val_mae: 11.5267
Epoch 5/100
22/22            0s 8ms/step - loss:
2683.7756 - mae: 16.0066 - val_loss: 290.0198 - val_mae: 11.5512
Epoch 6/100
22/22            0s 8ms/step - loss:
2065.2395 - mae: 15.2722 - val_loss: 256.7081 - val_mae: 11.7341
Epoch 7/100
22/22            0s 8ms/step - loss:
2138.8818 - mae: 15.2626 - val_loss: 233.9112 - val_mae: 11.8885
Epoch 8/100
22/22            0s 8ms/step - loss:
1699.0989 - mae: 14.7591 - val_loss: 212.0470 - val_mae: 11.6516
Epoch 9/100
22/22            0s 8ms/step - loss:
591.5463 - mae: 12.2466 - val_loss: 185.0415 - val_mae: 11.0957
Epoch 10/100
22/22            0s 8ms/step - loss:
1099.0573 - mae: 13.1499 - val_loss: 158.7979 - val_mae: 10.5965
Epoch 11/100
22/22            0s 8ms/step - loss:
575.2467 - mae: 11.3064 - val_loss: 113.5639 - val_mae: 8.9535
Epoch 12/100
22/22            0s 8ms/step - loss:
382.2814 - mae: 9.5320 - val_loss: 72.9015 - val_mae: 7.1576
Epoch 13/100
22/22            0s 15ms/step -
loss: 233.5213 - mae: 7.1710 - val_loss: 41.8935 - val_mae: 5.3041
Epoch 14/100
22/22            1s 11ms/step -
loss: 152.7788 - mae: 5.6675 - val_loss: 23.7709 - val_mae: 3.8422
Epoch 15/100
22/22            0s 15ms/step -
loss: 92.9965 - mae: 4.2542 - val_loss: 19.3603 - val_mae: 3.2980
Epoch 16/100
22/22            1s 11ms/step -
loss: 84.1271 - mae: 4.1618 - val_loss: 18.5885 - val_mae: 3.0831
Epoch 17/100
```

```
22/22            0s 17ms/step -
loss: 34.2037 - mae: 3.4492 - val_loss: 17.6995 - val_mae: 2.9895
Epoch 18/100
22/22            1s 16ms/step -
loss: 75.7129 - mae: 3.6236 - val_loss: 19.5392 - val_mae: 3.0082
Epoch 19/100
22/22            0s 9ms/step - loss:
39.8696 - mae: 3.5627 - val_loss: 17.7363 - val_mae: 2.9409
Epoch 20/100
22/22            0s 8ms/step - loss:
73.8139 - mae: 3.6528 - val_loss: 17.7032 - val_mae: 2.9076
Epoch 21/100
22/22            0s 9ms/step - loss:
38.8635 - mae: 3.1912 - val_loss: 17.9143 - val_mae: 2.8753
Epoch 22/100
22/22            0s 8ms/step - loss:
27.2303 - mae: 3.0362 - val_loss: 17.3584 - val_mae: 2.8341
Epoch 23/100
22/22            0s 8ms/step - loss:
27.7996 - mae: 3.0221 - val_loss: 16.5900 - val_mae: 2.8054
Epoch 24/100
22/22            0s 8ms/step - loss:
30.1323 - mae: 3.0432 - val_loss: 16.4584 - val_mae: 2.7824
Epoch 25/100
22/22            0s 7ms/step - loss:
25.3294 - mae: 2.8157 - val_loss: 16.0818 - val_mae: 2.7457
Epoch 26/100
22/22            0s 8ms/step - loss:
25.1970 - mae: 2.8494 - val_loss: 15.5105 - val_mae: 2.6978
Epoch 27/100
22/22            0s 8ms/step - loss:
27.3840 - mae: 2.8781 - val_loss: 15.5641 - val_mae: 2.7163
Epoch 28/100
22/22            0s 8ms/step - loss:
21.5095 - mae: 2.7178 - val_loss: 15.0726 - val_mae: 2.6348
Epoch 29/100
22/22            0s 8ms/step - loss:
20.0356 - mae: 2.6768 - val_loss: 14.6276 - val_mae: 2.6225
Epoch 30/100
22/22            0s 8ms/step - loss:
30.1239 - mae: 2.8798 - val_loss: 14.5792 - val_mae: 2.5867
Epoch 31/100
22/22            0s 8ms/step - loss:
27.5519 - mae: 2.9338 - val_loss: 13.5728 - val_mae: 2.5728
Epoch 32/100
22/22            0s 8ms/step - loss:
17.4098 - mae: 2.5558 - val_loss: 14.1464 - val_mae: 2.5140
Epoch 33/100
```

```
22/22            0s 8ms/step - loss:
21.5429 - mae: 2.6892 - val_loss: 12.9195 - val_mae: 2.4948
Epoch 34/100
22/22            0s 8ms/step - loss:
23.9844 - mae: 2.6620 - val_loss: 13.6543 - val_mae: 2.4886
Epoch 35/100
22/22            0s 8ms/step - loss:
27.4403 - mae: 2.5703 - val_loss: 13.1822 - val_mae: 2.4340
Epoch 36/100
22/22            0s 8ms/step - loss:
17.4918 - mae: 2.5334 - val_loss: 11.9144 - val_mae: 2.4163
Epoch 37/100
22/22            0s 8ms/step - loss:
18.1434 - mae: 2.5043 - val_loss: 12.0112 - val_mae: 2.3684
Epoch 38/100
22/22            0s 9ms/step - loss:
17.4200 - mae: 2.4417 - val_loss: 12.2327 - val_mae: 2.3386
Epoch 39/100
22/22            0s 8ms/step - loss:
26.2802 - mae: 2.5781 - val_loss: 11.7872 - val_mae: 2.3280
Epoch 40/100
22/22            0s 8ms/step - loss:
17.9369 - mae: 2.4725 - val_loss: 10.7344 - val_mae: 2.2950
Epoch 41/100
22/22            0s 8ms/step - loss:
24.5232 - mae: 2.5544 - val_loss: 11.7512 - val_mae: 2.2864
Epoch 42/100
22/22            0s 8ms/step - loss:
25.7331 - mae: 2.6546 - val_loss: 10.7561 - val_mae: 2.2795
Epoch 43/100
22/22            0s 8ms/step - loss:
16.0462 - mae: 2.2952 - val_loss: 10.4890 - val_mae: 2.2005
Epoch 44/100
22/22            0s 8ms/step - loss:
17.2484 - mae: 2.3953 - val_loss: 10.3503 - val_mae: 2.2045
Epoch 45/100
22/22            0s 9ms/step - loss:
20.9800 - mae: 2.4697 - val_loss: 10.4562 - val_mae: 2.2089
Epoch 46/100
22/22            0s 8ms/step - loss:
21.6691 - mae: 2.4368 - val_loss: 9.8670 - val_mae: 2.1415
Epoch 47/100
22/22            0s 8ms/step - loss:
17.9611 - mae: 2.3788 - val_loss: 9.5366 - val_mae: 2.1592
Epoch 48/100
22/22            0s 8ms/step - loss:
14.0447 - mae: 2.1003 - val_loss: 9.5508 - val_mae: 2.1388
Epoch 49/100
```

```
22/22            0s 8ms/step - loss:
14.3816 - mae: 2.2122 - val_loss: 8.7728 - val_mae: 2.0861
Epoch 50/100
22/22            0s 7ms/step - loss:
17.7713 - mae: 2.1835 - val_loss: 9.2523 - val_mae: 2.0472
Epoch 51/100
22/22            0s 8ms/step - loss:
19.4240 - mae: 2.2508 - val_loss: 8.8492 - val_mae: 2.0764
Epoch 52/100
22/22            0s 8ms/step - loss:
11.5259 - mae: 2.0718 - val_loss: 8.2048 - val_mae: 2.0062
Epoch 53/100
22/22            0s 8ms/step - loss:
10.4094 - mae: 2.0079 - val_loss: 8.5072 - val_mae: 1.9877
Epoch 54/100
22/22            0s 8ms/step - loss:
9.8661 - mae: 2.0133 - val_loss: 7.9909 - val_mae: 1.9682
Epoch 55/100
22/22            0s 10ms/step -
loss: 13.2642 - mae: 2.1460 - val_loss: 8.1128 - val_mae: 2.0152
Epoch 56/100
22/22            0s 12ms/step -
loss: 13.4205 - mae: 2.0999 - val_loss: 7.8421 - val_mae: 1.9693
Epoch 57/100
22/22            1s 13ms/step -
loss: 11.6933 - mae: 2.0378 - val_loss: 7.4812 - val_mae: 1.9254
Epoch 58/100
22/22            0s 11ms/step -
loss: 12.6938 - mae: 2.0424 - val_loss: 7.4107 - val_mae: 1.9007
Epoch 59/100
22/22            0s 11ms/step -
loss: 11.0986 - mae: 1.9531 - val_loss: 7.5735 - val_mae: 2.0229
Epoch 60/100
22/22            0s 15ms/step -
loss: 12.5241 - mae: 2.0077 - val_loss: 7.1932 - val_mae: 1.8888
Epoch 61/100
22/22            1s 15ms/step -
loss: 14.2891 - mae: 2.0492 - val_loss: 6.7663 - val_mae: 1.8843
Epoch 62/100
22/22            0s 9ms/step - loss:
8.1181 - mae: 1.8100 - val_loss: 6.6966 - val_mae: 1.8594
Epoch 63/100
22/22            0s 9ms/step - loss:
17.2844 - mae: 2.0944 - val_loss: 6.3768 - val_mae: 1.8171
Epoch 64/100
22/22            0s 7ms/step - loss:
11.6110 - mae: 1.9379 - val_loss: 6.4670 - val_mae: 1.8450
Epoch 65/100
```

```
22/22            0s 8ms/step - loss:
10.7655 - mae: 2.0313 - val_loss: 6.2028 - val_mae: 1.8545
Epoch 66/100
22/22            0s 8ms/step - loss:
18.1893 - mae: 2.0076 - val_loss: 6.4918 - val_mae: 1.8588
Epoch 67/100
22/22            0s 8ms/step - loss:
10.4320 - mae: 2.0450 - val_loss: 6.1728 - val_mae: 1.8466
Epoch 68/100
22/22            0s 8ms/step - loss:
7.0591 - mae: 1.7291 - val_loss: 5.7292 - val_mae: 1.7461
Epoch 69/100
22/22            0s 8ms/step - loss:
8.8987 - mae: 1.7852 - val_loss: 5.7689 - val_mae: 1.7472
Epoch 70/100
22/22            0s 9ms/step - loss:
11.8793 - mae: 1.9103 - val_loss: 5.4637 - val_mae: 1.7080
Epoch 71/100
22/22            0s 7ms/step - loss:
6.9557 - mae: 1.7103 - val_loss: 5.6374 - val_mae: 1.7875
Epoch 72/100
22/22            0s 8ms/step - loss:
6.4555 - mae: 1.6647 - val_loss: 5.2568 - val_mae: 1.6776
Epoch 73/100
22/22            0s 8ms/step - loss:
7.4748 - mae: 1.6767 - val_loss: 5.3831 - val_mae: 1.7304
Epoch 74/100
22/22            0s 9ms/step - loss:
7.4803 - mae: 1.7272 - val_loss: 5.0677 - val_mae: 1.6604
Epoch 75/100
22/22            0s 7ms/step - loss:
7.5050 - mae: 1.6878 - val_loss: 4.9619 - val_mae: 1.6649
Epoch 76/100
22/22            0s 8ms/step - loss:
9.1000 - mae: 1.7279 - val_loss: 4.8255 - val_mae: 1.6409
Epoch 77/100
22/22            0s 8ms/step - loss:
6.8122 - mae: 1.7186 - val_loss: 4.8118 - val_mae: 1.6685
Epoch 78/100
22/22            0s 8ms/step - loss:
8.0189 - mae: 1.7142 - val_loss: 4.6641 - val_mae: 1.6102
Epoch 79/100
22/22            0s 7ms/step - loss:
6.4051 - mae: 1.5535 - val_loss: 4.6474 - val_mae: 1.6352
Epoch 80/100
22/22            0s 8ms/step - loss:
5.1101 - mae: 1.5164 - val_loss: 4.6553 - val_mae: 1.6537
Epoch 81/100
```

```
22/22            0s 8ms/step - loss:
8.7564 - mae: 1.7471 - val_loss: 4.5163 - val_mae: 1.6028
Epoch 82/100
22/22            0s 8ms/step - loss:
6.2237 - mae: 1.6176 - val_loss: 4.4185 - val_mae: 1.6112
Epoch 83/100
22/22            0s 7ms/step - loss:
6.4293 - mae: 1.6253 - val_loss: 4.2579 - val_mae: 1.5721
Epoch 84/100
22/22            0s 8ms/step - loss:
4.9393 - mae: 1.5458 - val_loss: 4.3313 - val_mae: 1.6185
Epoch 85/100
22/22            0s 9ms/step - loss:
5.4414 - mae: 1.5866 - val_loss: 4.5984 - val_mae: 1.6764
Epoch 86/100
22/22            0s 9ms/step - loss:
7.4136 - mae: 1.6006 - val_loss: 4.1220 - val_mae: 1.5392
Epoch 87/100
22/22            0s 7ms/step - loss:
7.9413 - mae: 1.6199 - val_loss: 4.1578 - val_mae: 1.5741
Epoch 88/100
22/22            0s 8ms/step - loss:
5.6956 - mae: 1.5892 - val_loss: 4.0152 - val_mae: 1.5419
Epoch 89/100
22/22            0s 8ms/step - loss:
6.7526 - mae: 1.6818 - val_loss: 4.4353 - val_mae: 1.6729
Epoch 90/100
22/22            0s 8ms/step - loss:
5.6151 - mae: 1.5560 - val_loss: 3.9537 - val_mae: 1.5235
Epoch 91/100
22/22            0s 7ms/step - loss:
4.3817 - mae: 1.4753 - val_loss: 3.7926 - val_mae: 1.4933
Epoch 92/100
22/22            0s 8ms/step - loss:
5.2421 - mae: 1.5586 - val_loss: 3.7549 - val_mae: 1.4982
Epoch 93/100
22/22            0s 7ms/step - loss:
5.2265 - mae: 1.4613 - val_loss: 3.7635 - val_mae: 1.4999
Epoch 94/100
22/22            0s 8ms/step - loss:
4.9829 - mae: 1.4876 - val_loss: 3.7273 - val_mae: 1.4893
Epoch 95/100
22/22            0s 9ms/step - loss:
5.9616 - mae: 1.5412 - val_loss: 3.6481 - val_mae: 1.4822
Epoch 96/100
22/22            0s 8ms/step - loss:
4.0807 - mae: 1.3928 - val_loss: 3.6298 - val_mae: 1.4801
Epoch 97/100
```

```
22/22             0s 9ms/step - loss:
4.0583 - mae: 1.3839 - val_loss: 3.6569 - val_mae: 1.4757
Epoch 98/100
22/22             0s 9ms/step - loss:
4.1025 - mae: 1.4322 - val_loss: 3.5626 - val_mae: 1.4698
Epoch 99/100
22/22             0s 17ms/step -
loss: 4.9102 - mae: 1.4640 - val_loss: 3.6736 - val_mae: 1.4715
Epoch 100/100
22/22             1s 15ms/step -
loss: 4.4893 - mae: 1.4167 - val_loss: 3.4755 - val_mae: 1.4391
```

[ ]:
```python
# GRAFICANDO RESULTADOS
predicciones = modelo.predict(X_prueba)

import matplotlib.pyplot as plt

plt.scatter(y_prueba, predicciones)
plt.xlabel("Valor real de PM 2.5")
plt.ylabel("Predicción de PM 2.5")
plt.title("Red Neuronal: Predicción vs Real")
plt.grid(True)
plt.show()
```

```
10/10             0s 12ms/step
```

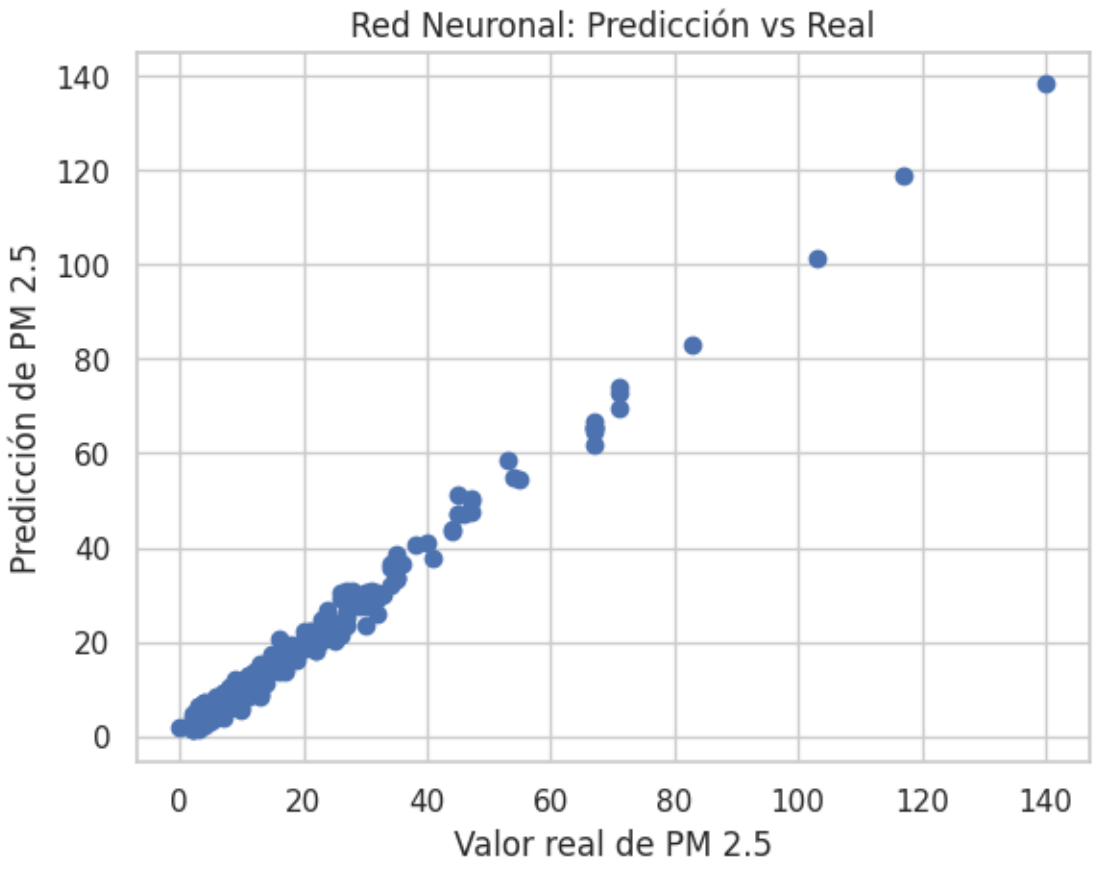

5 Estimacion de los demas parámetros

[ ]:
```
# Lista de contaminantes como variables objetivo
contaminantes = ['co','co2', 'pm10', 'pm2_5', 'pm5', 'humedad_relativa',␣
 ↪'temperatura']

# matriz de subplots
filas = 4
columnas = 2
fig, axes = plt.subplots(filas, columnas, figsize=(12, 12))
axes = axes.flatten()  # Aplanar para indexar fácilmente

for i, contaminante in enumerate(contaminantes):
    #Preparar datos
    X = aire.drop(columns=[contaminante, 'fecha', 'nombre_equipo'])
    y = aire[contaminante]

    # División data entrenamiento - prueba
```

```
    X_entrenamiento, X_prueba, y_entrenamiento, y_prueba = train_test_split(
        X, y, test_size=0.3, random_state=42)

    #Escalamiento
    escalador = StandardScaler()
    X_entrenamiento = escalador.fit_transform(X_entrenamiento)
    X_prueba = escalador.transform(X_prueba)

    #Modelo
    modelo = models.Sequential([
        layers.Dense(64, activation='relu', input_shape=(X_entrenamiento.
 ↪shape[1],)),
        layers.Dense(64, activation='relu'),
        layers.Dense(1)
    ])
    modelo.compile(optimizer='adam', loss='mse', metrics=['mae'])

     #Entrenamiento
    modelo.fit(X_entrenamiento, y_entrenamiento, epochs=100,
               validation_data=(X_prueba, y_prueba), verbose=0)
    predicciones = modelo.predict(X_prueba)

    #Gráfico
    axes[i].scatter(y_prueba, predicciones, alpha=0.6)
    axes[i].set_title(f"Predicción vs Real: {contaminante}")
    axes[i].set_xlabel("Valor real")
    axes[i].set_ylabel("Predicción")
    axes[i].grid(True)

# Se ocultan espacion si hay graficos vacios
if len(contaminantes) < len(axes):
    for j in range(len(contaminantes), len(axes)):
        fig.delaxes(axes[j])

fig.suptitle("Red Neuronal - Comparación Real vs Predicho por contaminante",␣
 ↪fontsize=16)
plt.tight_layout(rect=[0, 0.03, 1, 0.95])
plt.show()
```

```
/usr/local/lib/python3.11/dist-packages/keras/src/layers/core/dense.py:87:
UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When
using Sequential models, prefer using an `Input(shape)` object as the first
layer in the model instead.
  super().__init__(activity_regularizer=activity_regularizer, **kwargs)
```

```
10/10            0s 11ms/step
```

```
/usr/local/lib/python3.11/dist-packages/keras/src/layers/core/dense.py:87:
```

```
UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When
using Sequential models, prefer using an `Input(shape)` object as the first
layer in the model instead.
  super().__init__(activity_regularizer=activity_regularizer, **kwargs)

10/10            0s 10ms/step

/usr/local/lib/python3.11/dist-packages/keras/src/layers/core/dense.py:87:
UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When
using Sequential models, prefer using an `Input(shape)` object as the first
layer in the model instead.
  super().__init__(activity_regularizer=activity_regularizer, **kwargs)

10/10            0s 9ms/step

/usr/local/lib/python3.11/dist-packages/keras/src/layers/core/dense.py:87:
UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When
using Sequential models, prefer using an `Input(shape)` object as the first
layer in the model instead.
  super().__init__(activity_regularizer=activity_regularizer, **kwargs)

10/10            0s 9ms/step

/usr/local/lib/python3.11/dist-packages/keras/src/layers/core/dense.py:87:
UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When
using Sequential models, prefer using an `Input(shape)` object as the first
layer in the model instead.
  super().__init__(activity_regularizer=activity_regularizer, **kwargs)

10/10            0s 9ms/step

/usr/local/lib/python3.11/dist-packages/keras/src/layers/core/dense.py:87:
UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When
using Sequential models, prefer using an `Input(shape)` object as the first
layer in the model instead.
  super().__init__(activity_regularizer=activity_regularizer, **kwargs)

10/10            0s 9ms/step

/usr/local/lib/python3.11/dist-packages/keras/src/layers/core/dense.py:87:
UserWarning: Do not pass an `input_shape`/`input_dim` argument to a layer. When
using Sequential models, prefer using an `Input(shape)` object as the first
layer in the model instead.
  super().__init__(activity_regularizer=activity_regularizer, **kwargs)

10/10            0s 9ms/step
```

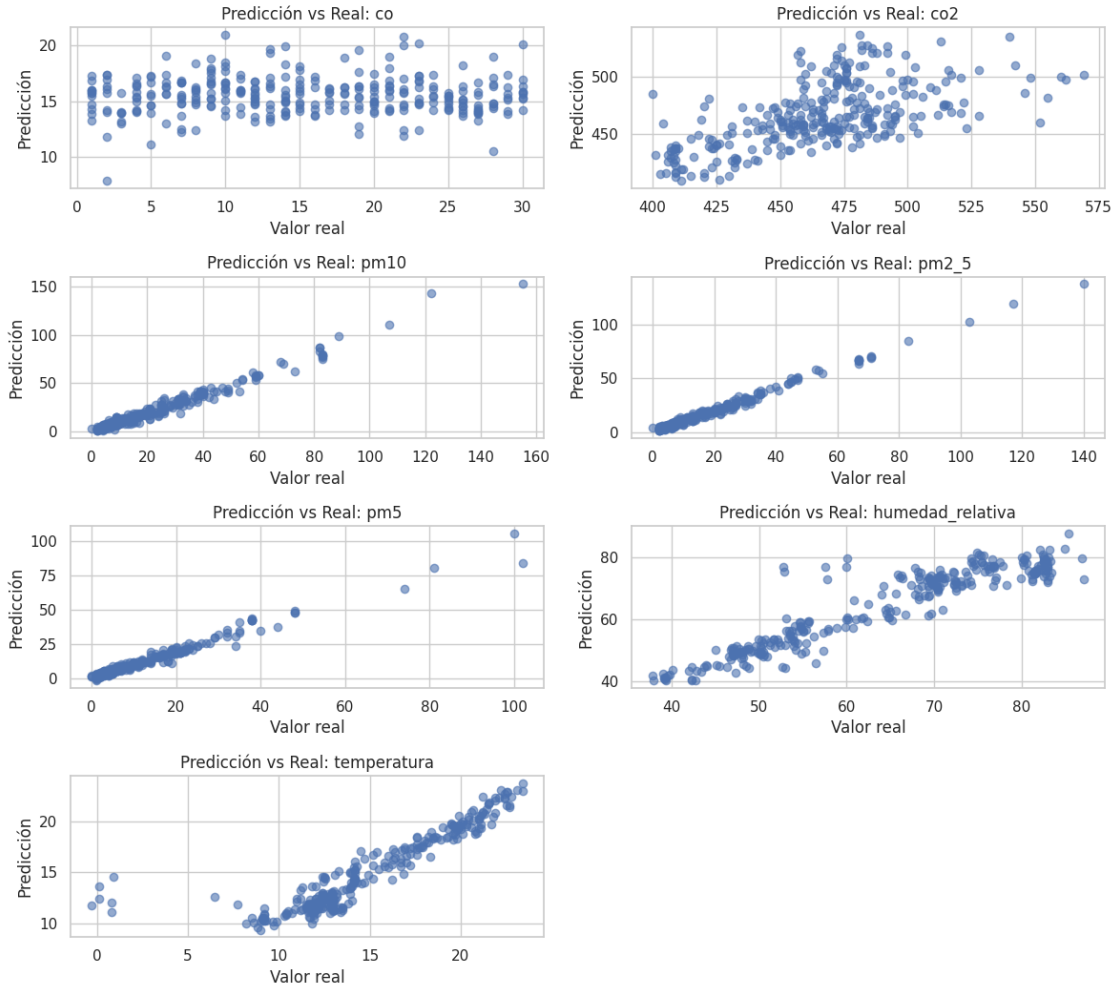

5.0.1 Conclusiones

- Algunas de las variables se pueden predecir con alta fiabilidad como pm(2.5, 5, 10), temperatura y humedad relativa aunque, estas ultimas dos, tienen al parecer valores atipicos en valores cercanos o iguales a cero como se habia planteado incialmente esto puede ocurrir por fallas en el sensor.